PortMatch

오류가 있는 입항 기록을 정답 선박으로 연결하다

한글 음차·영문 오타·잘못된 톤수로 달라진 기록.
후보 검색과 순위 학습을 결합하고, 실패 조건을 나누어 개선했다.

Python · scikit-learn · LightGBM LambdaRank

최종 PUBLIC 점수

0.85154

+6.02%p 첫 제출 대비 · 점수 +0.06019

최종 모델 focused_search fold0
Public 0.8515414798 · 단일 fold 모델

12,222
학습 입항 기록 · 5,851척

86
이름·메타데이터 비교 특징

5-fold
선박 단위 개발 검증

5,293
저장된 예측과 일치한 ZIP 예측

01 / SOLUTION 실패를 검색과 순위 문제로 나누다

INPUT
불완전한 기록
한글·영문 이름 오류
톤수·국적·선종 결측

→

RETRIEVAL
후보 검색
문자·음차·호출부호·톤수
한글 정답 후보 검색 확대

→

RANKING
순위 학습
86개 특징으로 후보 비교
LightGBM LambdaRank

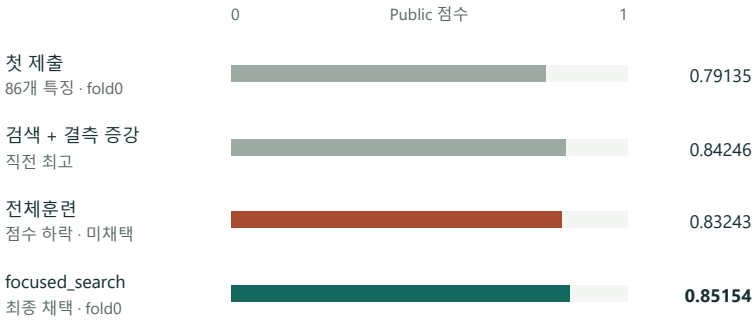
→

OUTPUT
선박 ID 하나
고정 모델로 행별 추론
독립 실행 가능한 제출 ZIP

정답 후보가 없다면 → 한글 검색을 확대해 후보 회복

정답이 순위에서 밀린다면 → 복합 오류 증강·어려운 오답 학습

02 / RESULT 실제 제출 점수의 변화



제출 기록 기준. 전체훈련 모델의 하락도 포함했다.
각 변경의 Public 기여를 개별적으로 분리한 결과는 아니다.

03 / VALIDATION 검증을 제출물까지 연결

1. **선박 단위로 분리**
동일 선박의 반복 입항이 학습·검증에 섞이지 않게 외부 5-fold와 내부 분할 적용.

2. **25개 입력 조건으로 후속 비교**
이름 보강·톤수 보강·동시 적용을 분리하고 원본과 기존 오류 조건의 성능 유지 확인.

3. **복원·입력 순서 독립성 확인**
원본·역순·부분·단일 입력 등 5,293개 예측이 저장 결과와 일치.
정답률 100%를 뜻하지 않음.

어디에서 개선됐고, 왜 멈췄는가

공개 데이터 12,222행 · 전체 5-fold

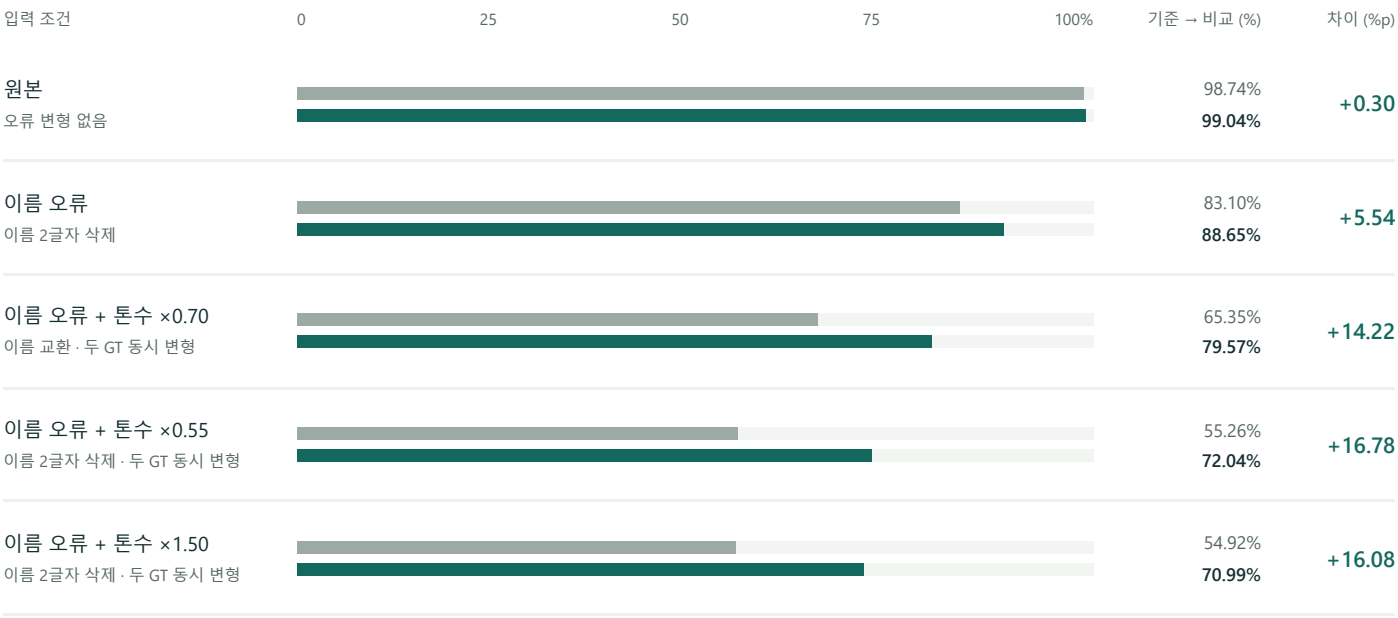
후보 누락과 순위 오류를 구분하고, 보강 방법을 각각 비교했다. 점수가 오른 조건과 함께 원본·기존 오류 조건의 손실도 모델 선택에 반영했다.

선택한 비교: 직전 최고 설정 → focused_search

직전 최고 설정 → focused_search

직전 최고 설정 · 최종 모델

한글 70% · 비한글 30% 가중 Top-1 (%) · 선박 5-fold 합산



실제 Public 상승을 확인한 최종 모델

표시된 조건이 개선됐다. 이 비교는 5-fold 개발 검증이며, 실제 제출에는 focused_search fold0 단일 모델을 사용했다.

표시된 5조건은 주요 사례다. 전체 후속 실험은 25조건이며, 최종 모델은 이전 20조건 실험에서 평가했다. 이 수치는 실제 단일 fold 제출의 Public 점수가 아니다.

마지막 동시 보강을 채택하지 않은 이유

아래 차이는 focused_search 대비 후속 동시 보강의 전체 5-fold 결과다. ×0.70은 이름 교환, ×0.55는 이름 2글자 삭제를 동반한다.

두 톤수 ×0.70	두 톤수 ×0.55	원본 입력
+3.0220	**−3.5307**	**−0.3608**
%p 개선	%p 하락	%p 하락

후속 세 모델 모두 사전 유지 기준을 통과하지 못했다. **검증된 focused_search를 최종 모델로 유지했다.**

남은 한계

1. **한글 데이터의 범위**
   1,191행·382척으로 제한적. 비공개 입력의 실패 원인은 직접 확인하지 못했다.
2. **반복 검증에 따른 선택 편향**
   같은 검증 집합을 반복 사용했다. 내부 점수를 독립적인 실서비스 성능으로 해석하지 않는다.
3. **완료 범위**
   대회 제출·독립 실행 검증까지 완료. 운영 배포는 미수행이며 최종 Private·순위는 미확인.

실패 원인 분석 → 통제된 비교 실험 → 성능 저하를 포함한 모델 선택 → 제출 재현성 검증

모델을 만드는 과정과 함께, 어떤 결과를 근거로 채택하거나 보류했는지를 남겼다.

근거: 프로젝트 종료 보고서 · 최종 모델 5-fold 비교 · 후속 보강 비교 · 수치와 원본 파일 해시

Public은 제출 화면 확인 기록과 사용자 보고 기준. 최초·중간·최종 제출의 기록을 구분했다. 문서화 2026-11-07 · 기존 종료 보고서·모델·제출물 보존.